Highway Networks – Dokumentacja Projektu (CIFAR-10)

Opracowano na podstawie pracy: Rupesh Kumar Srivastava, Klaus Greff, Jürgen Schmidhuber (2015), arXiv:1505.00387v2

1. Podstawy teoretyczne architektury Highway Network

1.1. Problemy optymalizacji głębokich sieci neuronowych

W klasycznej jednokierunkowej sieci neuronowej (plain network) każda z L warstw przekształca wejście x za pomocą transformacji afinicznej sparametryzowanej macierzą wag W_H oraz nieliniowej funkcji aktywacji (np. ReLU):

$$y = H(x, W_H)$$

Gdy połączymy sekwencyjnie 20, 50 lub 100 takich warstw, w procesie optymalizacji pojawiają się dwa fundamentalne zjawiska utrudniające zbieżność:

- **Degradacja sygnału podczas propagacji w przód:** W początkowej fazie procesu uczenia wagi W_H są inicjalizowane losowo. Wielokrotne przekształcenia liniowo-nieliniowe powodują stopniową utratę informacji o pierwotnej reprezentacji wejściowej na dużych głębokościach sieci.
- **Zanikające gradienty podczas propagacji wstecznej:** Gradient funkcji kosztu wyznaczany zgodnie z regułą łańcuchową stanowi iloczyn jakobianów wszystkich pośrednich warstw. Wraz ze wzrostem głębokości norma gradientu docierającego do początkowych warstw drastycznie maleje, co uniemożliwia efektywną optymalizację bardzo głębokich architektur klasycznych za pomocą algorytmu SGD.

1.2. Mechanizm bramkowania i autostrady informacyjne

Autorzy pracy zaczerpnęli inspirację z architektury rekurencyjnych sieci LSTM (Long Short-Term Memory). Zamiast wymuszać pełną nieliniową transformację sygnału w każdej warstwie, wprowadzono wyuczalny mechanizm bramkujący, który w sposób adaptacyjny reguluje przepływ informacji pomiędzy warstwami, określając, w jakim stopniu wejście podlega przekształceniu H(x, W_H), a w jakim zostaje bezpośrednio przeniesione do kolejnej warstwy bez modyfikacji. Powstające w ten sposób ścieżki umożliwiające propagację sygnału przez wiele warstw bez tłumienia określono mianem autostrad informacyjnych (information highways).

1.3. Model matematyczny warstwy Highway

Do nieliniowej transformacji H(x, W_H) dodajemy dwie funkcje bramkujące:

- **Bramkę transformacji (Transform Gate):** $T(x, W_T) = \sigma(W_T \cdot x + b_T)$
- **Bramkę przenoszenia (Carry Gate):** $C(x, W_C) = 1 - T(x, W_T)$

Funkcja sigmoidalna $\sigma(z) = 1 / (1 + \exp(-z))$ przyjmuje wartości z przedziału (0, 1), pełniąc funkcję ciągłego współczynnika wagowego. Wyjście warstwy Highway opisane jest równaniem:

$$y = H(x, W_H) \cdot T(x, W_T) + x \cdot (1 - T(x, W_T))$$

Własności warstwy oraz jakobianu dy/dx w stanach granicznych bramki T:

- **Dla zamkniętej bramki transformacji (T(x) = 0):** y = x oraz dy/dx = I (macierz jednostkowa). Warstwa realizuje odwzorowanie tożsamościowe, a gradient błędu podczas propagacji wstecznej przechodzi w stosunku 1:1 bez żadnego tłumienia.
- **Dla otwartej bramki transformacji (T(x) = 1):** y = H(x, W_H) oraz dy/dx = H'(x, W_H). Warstwa zachowuje się identycznie jak warstwa klasycznej sieci jednokierunkowej.

1.4. Rola ujemnej inicjalizacji biasu bramki (b_T < 0) w początkowej fazie procesu uczenia

W początkowej fazie uczenia wagi W_H mają rozkład losowy o średniej zerowej. Aby zapobiec degradacji sygnału oraz umożliwić swobodną propagację gradientów od pierwszych iteracji, wektor biasu bramki transformacji b_T inicjalizujemy wartością ujemną (np. b_T = −2.0 lub b_T = −4.0):

- **Dla b_T = −2.0:** $\sigma(-2.0) \approx 0.12 \rightarrow 1 - T \approx 0.88$ (ok. 88% sygnału podlega bezpośredniemu przeniesieniu ścieżką carry).
- **Dla b_T = −4.0:** $\sigma(-4.0) \approx 0.018 \rightarrow 1 - T \approx 0.98$ (ok. 98% sygnału podlega bezpośredniemu przeniesieniu ścieżką carry).

Dzięki takiej inicjalizacji sieć w początkowych epokach faworyzuje odwzorowanie tożsamościowe, natomiast w trakcie procesu optymalizacji parametry bramek T ulegają adaptacji, selektywnie zwiększając udział ścieżki transformacji w warstwach istotnych dla minimalizacji funkcji kosztu.

1.5. Wymiarowość reprezentacji i warstwy konwolucyjne

Równanie $y = H(x) \cdot T(x) + x \cdot (1 - T(x))$ wymaga zgodności wymiarów tensorów x, y, H(x) oraz T(x). W konwolucyjnych warstwach Highway (HighwayConv2d) zarówno H, jak i T są realizowane jako niezależne operacje splotu 3×3 o tej samej liczbie filtrów i z dopełnieniem zerami (padding = 1), co gwarantuje zachowanie wymiarów przestrzennych map cech. Gdy zwiększamy liczbę kanałów (np. 3 → 32 lub 32 → 48), stosujemy pojedynczą warstwę konwolucyjną bez bramki (PlainTransitionConv2d), po której układamy kaskadę warstw Highway o stałej liczbie kanałów.

2. Architektura kodu, metodologia ewaluacji i opis implementacji

2.1. Moduł highway_network.py

Moduł zawiera implementację warstw Highway dla reprezentacji wektorowych (HighwayLinear) oraz map cech 2D (HighwayConv2d), warstwę przejściową PlainTransitionConv2d, a także kompletne architektury konwolucyjne (ConvHighwayNet) i w pełni połączone (DeepFCHighwayNet).

```
class HighwayConv2d(nn.Module):
    def __init__(self, channels, kernel_size=3, transform_bias=-2.0, use_bn=True):
        super().__init__()
        padding = kernel_size // 2
        self.H = nn.Conv2d(channels, channels, kernel_size=kernel_size, padding=padding, bias=not use_bn)
        self.bn_h = nn.BatchNorm2d(channels) if use_bn else nn.Identity()
        self.T = nn.Conv2d(channels, channels, kernel_size=kernel_size, padding=padding, bias=True)
        self.last_gate = None
        self.last_output = None
        self._init_weights(transform_bias)

    def forward(self, x):
        h = F.relu(self.bn_h(self.H(x)))
        t = torch.sigmoid(self.T(x))
        out = h * t + x * (1.0 - t)
        if not self.training:
            self.last_gate = t.detach()
            self.last_output = out.detach()
        return out
```

- **build_highway11_cifar10:** 3 etapy o liczbie kanałów (32, 48, 64) i liczbie warstw Highway (2, 3, 2). Łącznie 11 warstw parametrycznych (3 warstwy przejściowe + 7 warstw HighwayConv2d + klasyfikator liniowy), 353 018 parametrów.
- **build_highway19_cifar10:** 3 etapy o liczbie kanałów (64, 96, 128) i liczbie warstw Highway (5, 5, 5). Łącznie 19 warstw parametrycznych (3 warstwy przejściowe + 15 warstw HighwayConv2d + klasyfikator liniowy), 2 846 442 parametrów.
- **DeepFCHighwayNet / DeepFCPlainNet:** Głębokie sieci w pełni połączone (50 jednostek na warstwę ukrytą dla

Highway, 71 dla Plain przy porównywalnej liczbie parametrów) służące do badania zbieżności optymalizacji przy dużej głębokości.

2.2. Moduł train_cifar10.py – kontrakt zbioru danych, poziom bazowy i metryki

- **Kontrakt podziału danych i brak wycieku informacji (get_cifar10_loaders):** Zbiór 50 000 obrazów treningowych CIFAR-10 dzielony jest ze stratyfikacją (train_test_split, random_state=42) na część treningową (45 000 obrazów, po 4 500 na klasę) oraz walidacyjną (5 000 obrazów, po 500 na klasę). Statystyki standaryzacji (średnia i odchylenie standardowe kanałów RGB) wyznaczane są wyłącznie na 45 000 obrazach treningowych i stosowane do przeskalowania zbiorów train, val oraz test (brak preprocessing leakage). Augmentacja losowa (RandomCrop(32, padding=4), RandomHorizontalFlip) aplikowana jest wyłącznie do zbioru treningowego.
- **Poziom odniesienia (compute_dummy_baseline):** Przed rozpoczęciem treningu wyznaczany jest wynik klasyfikatora bazowego (Dummy Baseline) na zbiorze walidacyjnym: Val Acc = 10.00%, Val Macro F1 = 1.82% oraz teoretyczna strata rozkładu jednostajnego ln(10) ≈ 2.3026.
- **Rozgraniczenie funkcji straty i metryk oraz jednokrotna ewaluacja testowa (train_one_epoch / evaluate):** Różniczkowalnym surogatem minimalizowanym w pętli (forward → loss → backward → step) przez SGD z momentum (0.9) i regularyzacją L2 (weight_decay=5e-4) jest entropia krzyżowa. Selekcja najlepszego modelu (best_highway_cifar10.pt) odbywa się wyłącznie na podstawie zbioru walidacyjnego (Val Acc). Zbiór testowy (10 000 obrazów) oceniany jest dokładnie jeden raz po zakończeniu uczenia z wyznaczeniem Accuracy (wraz z 95% przedziałem ufności), Macro Precision, Macro Recall, Macro F1 oraz macierzy pomyłek 10×10.

2.3. Moduł test_highway_network.py

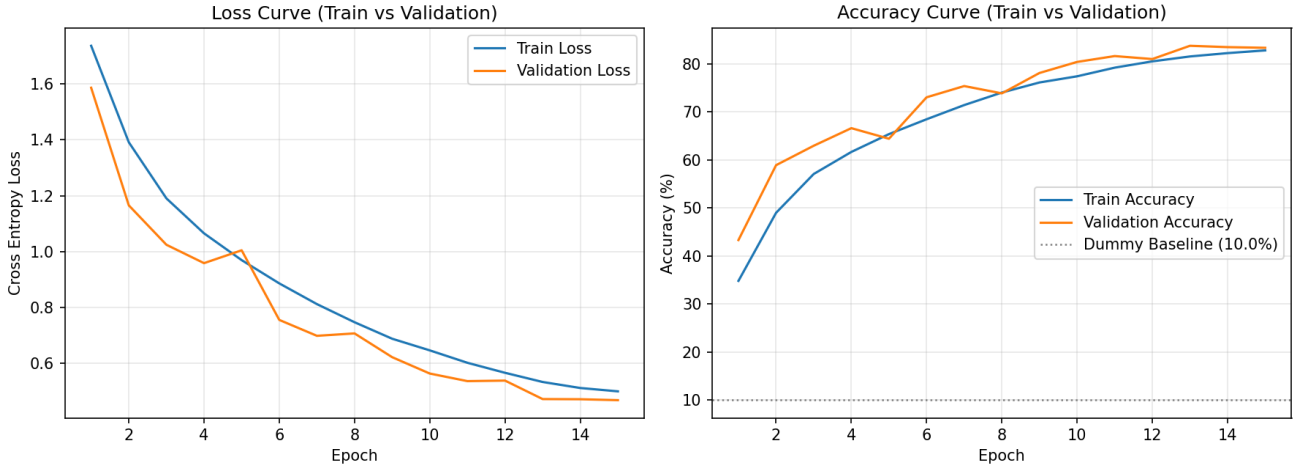
Zestaw 10 testów automatycznych (unittest) weryfikujących poprawność matematyczną, metodologiczną i implementacyjną:

- **1. test_highway_linear_shapes_and_gate_bounds:** Weryfikacja wymiarów tensorów oraz ograniczenia wartości bramki T w przedziale (0, 1) w warstwie liniowej.
- **2. test_highway_conv2d_shapes_and_zero_padding:** Weryfikacja zachowania wymiarów 32×32 dzięki dopełnieniu zerami w HighwayConv2d.
- **3. test_equation_4_carry_and_transform_regimes:** Weryfikacja Równania (4): y = x dla T → 0 oraz y = H(x) dla T → 1.
- **4. test_equation_5_jacobian_identity_when_gate_closed:** Weryfikacja Równania (5): zachowanie jednostkowego jakobianu dy/dx = I (brak tłumienia gradientu) dla T → 0.
- **5. test_negative_bias_initialization:** Weryfikacja inicjalizacji wektora biasu b_T wartościami ujemnymi (−1.0, −2.0, −4.0).
- **6. test_optimization_in_50_layer_highway_vs_plain:** Porównanie procesu optymalizacji 50-warstwowej sieci Highway i 50-warstwowej sieci klasycznej; sieć Highway osiąga zbieżność, podczas gdy w sieci klasycznej proces optymalizacji ulega stagnacji.
- **7. test_plain_transition_conv_changes_dimensionality:** Weryfikacja zmiany liczby kanałów przez warstwę PlainTransitionConv2d.
- **8. test_conv_highway_architectures_forward_backward:** Weryfikacja propagacji w przód i wstecz oraz niezerowości norm gradientów dla architektur highway11 i highway19.
- **9. test_dataset_contract_stratification_and_dummy_baseline:** Weryfikacja stratyfikowanego podziału 45 000 / 5 000 / 10 000, standaryzacji wyznaczonej wyłącznie na zbiorze treningowym oraz wartości klasyfikatora bazowego (10.0% dokładności, strata ln(10)).
- **10. test_trained_checkpoint_on_cifar10:** Weryfikacja wytrenowanego modelu best_highway_cifar10.pt na zbiorze testowym (dokładność z 95% CI, Macro F1 oraz macierz pomyłek 10×10).

3. Wyniki treningu i analiza eksperymentalna na zbiorze CIFAR-10

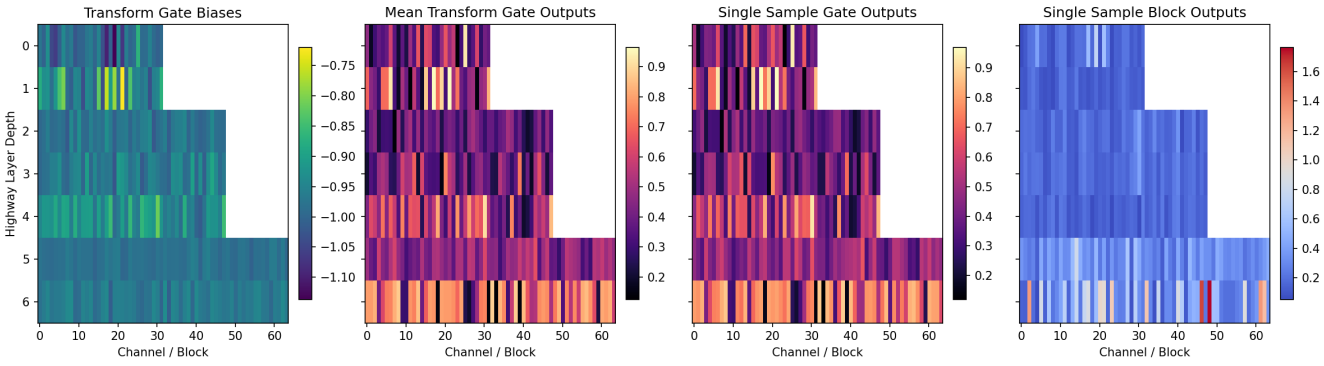
3.1. Przebieg uczenia i walidacji oraz końcowa ewaluacja testowa modelu highway11

Model konwolucyjny highway11 (353 018 parametrów, b_T = −2.0) został poddany 15-epokowemu procesowi uczenia na zbiorze treningowym (45 000 obrazów) i monitorowany na zbiorze walidacyjnym (5 000 obrazów). Najwyższą dokładność walidacyjną osiągnięto w 13. epoce (Val Acc = 83.74%, Val Macro F1 = 83.64% wobec poziomu odniesienia Dummy Baseline = 10.00%). Wybrany model z 13. epoki oceniono jednokrotnie na zbiorze testowym (10 000 obrazów), uzyskując Test Loss = 0.4882, Test Accuracy = 83.50% (95% CI [82.77%, 84.23%]), Macro Precision = 83.36%, Macro Recall = 83.50% oraz Macro F1 = 83.37%.



3.2. Analiza bramek transformujących i autostrad informacyjnych

Poniższy wykres przedstawia wewnętrzne stany 7 konwolucyjnych warstw Highway (głębokości 0–6 na osi pionowej; schodkowa szerokość wynika ze zmiany liczby kanałów w kolejnych etapach: 32 → 48 → 64):



- **Transform Gate Biases:** Wartości biasów b_T pozostają ujemne po zakończeniu uczenia, co sprzyja selektywnemu działaniu bramek transformujących.
- **Mean Transform Gate Outputs:** W początkowych warstwach znaczna część kanałów wykazuje niską średnią aktywność bramki T (rzędu 0.2–0.3), co oznacza dominację ścieżki przenoszenia (carry), podczas gdy głębsze warstwy w większym stopniu wykorzystują nieliniową transformację cech.
- **Single Sample Gate Outputs & Block Outputs:** Dla pojedynczej próbki wejściowej aktywność bramek T ma charakter selektywny i zależy od bieżącego wzorca wejściowego, a wyjścia bloków zachowują stabilną amplitudę na całej głębokości sieci.